



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y
Tecnología

Máster Universitario en Análisis y Visualización de Datos
Masivos

Análisis de Ventas y Pronósticos para la
optimización de Inventarios y Retención
de Clientes.

Trabajo fin de estudio presentado por:	Héctor Miguel Silva Garnica Juan Salvador Rodríguez Aguirre Omar Gaspar Ramírez María Fernanda Zúniga Arteaga
Tipo de trabajo:	Descripción general del proyecto y alcances
Versión:	3.2
Director/a:	Barbaro Jorge Ferro Castro
Fecha:	13/09/2026

Resumen

La gestión eficiente del inventario constituye uno de los principales desafíos en los establecimientos de alimentos preparados que utilizan insumos perecederos, debido a la variabilidad de la demanda y a la limitada vida útil de los productos. En este contexto, el presente trabajo propone el diseño de una arquitectura analítica orientada a la predicción de ventas y a la optimización de la planeación de inventarios para una cadena de restaurantes especializada en poke bowls. La propuesta integra técnicas de procesamiento y almacenamiento de datos, análisis exploratorio, modelado predictivo de series temporales y minería de datos para apoyar la toma de decisiones comerciales.

Como parte del desarrollo, se plantea la digitalización de la información operativa, la aplicación de procesos de limpieza y estandarización de datos, la generación de datos sintéticos para complementar el historial disponible y el diseño de una arquitectura escalable con potencial de migración hacia entornos de procesamiento distribuido. Asimismo, se propone el desarrollo de un tablero interactivo que permita visualizar indicadores clave de desempeño relacionados con ventas, inventario, mermas y pronósticos de demanda. Con ello, se busca proporcionar una herramienta de apoyo que contribuya a mejorar la planificación de compras, reducir el desperdicio de insumos y fortalecer el proceso de toma de decisiones basado en datos.

Palabras clave: Gestión de inventarios, Analítica de datos, Predicción de ventas, Datos sintéticos, Modelado documental, Minería de datos, Visualización de datos.

Abstract

Efficient inventory management represents one of the main challenges faced by food service businesses that rely on perishable ingredients, as fluctuations in customer demand and the limited shelf life of products can lead to inventory shortages and food waste. In this context, this project proposes the design of a data analytics architecture aimed at improving demand forecasting and inventory planning for a chain of poke bowl restaurants. The proposed solution integrates data processing and storage techniques, exploratory data analysis, time series forecasting, and data mining methods to support business decision-making.

The proposed methodology includes the digitization of operational records, data cleaning and standardization processes, the generation of synthetic data to complement the limited historical information available, and the design of a scalable architecture with the potential to migrate to distributed computing environments. Additionally, an interactive dashboard is proposed to visualize key performance indicators related to sales, inventory levels, food waste, and demand forecasts. The overall objective is to provide a decision-support tool that contributes to more efficient purchasing planning, reduces inventory losses caused by perishable products, and promotes data-driven decision-making in the restaurant industry.

Keywords: Inventory management, Data analytics, Sales forecasting, Synthetic data, Document modeling, Data mining, Data visualization.

Índice de contenidos

Contenido

Resumen	2
Abstract	3
1. Introducción	6
1.1. Objetivos del Proyecto	7
1.2. Alcance del Proyecto y Limitaciones	8
1.3. Estructura del Informe.....	9
2. Descripción de los datos	9
2.1. Identificación y origen de las fuentes de datos.....	10
2.2. Descripción de las Variables Relevantes	11
Diccionario de datos.....	12
Proceso de Recolección y Herramienta de Almacenamiento	12
Limpieza, Preprocesamiento y Reglas de Calidad	13
Tamaño, Restricciones y Generación de Datos Sintéticos	14
Privacidad y Confidencialidad	15
2.3. Modelado de Datos.....	16
2.4. Generación de Datos Sintéticos y Análisis exploratorio de datos (EDA)	18
Diagnóstico de la Necesidad y Objetivo	18
Herramientas Utilizadas	18
Proceso Metodológico para la Generación de Datos	18
3. Análisis Exploratorio de Datos (EDA).....	21

Resumen ejecutivo	21
Información grafica.....	23
Evaluación de Supuestos Clave.....	29
4. Metodología	31
4.1. Modelado Predictivo de Series Temporales.....	31
4.2. Selección y justificación de las técnicas de análisis.....	34
4.3. Detalle del proceso de análisis (Pipeline de datos).....	35
4.4. Herramientas y software utilizados.....	36
4.5. Supuestos y limitaciones de la metodología	37
5. Resultados y Visualización.....	39
5.1. Evaluación y discusión de resultados	39
5.2. Pruebas de sensibilidad.....	45
5.3. Alineación de Hallazgos con los Objetivos del Proyecto	47
5.4. Análisis de Robustez y Validez de los Resultados.....	50
5.5. Propuestas de Mejora y Extensiones Futuras	51
6. Prototipo de la solución	52
7. Conclusiones, recomendaciones y próximos pasos	53
8. Referencias bibliográficas.....	56

1. Introducción

El análisis de datos se ha convertido en una herramienta fundamental para las organizaciones, permitiéndoles optimizar procesos, comprender el comportamiento de sus clientes y apoyar la toma de decisiones basada en información. En un entorno cada vez más competitivo, la adopción de tecnologías de análisis y procesamiento de datos representa una ventaja para mejorar la eficiencia operativa y fortalecer la competitividad de los negocios.

El objeto de estudio de este proyecto es HAKAPOKES, una cadena de restaurantes de comida rápida saludable ubicada en el estado de Querétaro. Este establecimiento se especializa en la preparación de *poke bowls*, un platillo de origen hawaiano que permite a los clientes personalizar su orden mediante la selección de diferentes bases, proteínas, vegetales, complementos (*toppings*) y salsas.

Si bien este modelo de negocio resulta atractivo por el alto nivel de personalización que ofrece, su operación depende en gran medida de la disponibilidad y frescura de ingredientes como salmón, atún, aguacate, mango y otros productos perecederos. Debido a su corta vida útil, una planeación inadecuada del inventario puede generar pérdidas económicas importantes derivadas tanto del desperdicio de alimentos como de la falta de disponibilidad de productos para satisfacer la demanda.

Actualmente, la planeación de compras y el abastecimiento de insumos en cada sucursal se realizan principalmente con base en la experiencia del personal responsable y en promedios semanales de ventas. Aunque este procedimiento ha permitido mantener la operación del negocio, presenta limitaciones para anticipar cambios en la demanda ocasionados por factores como la estacionalidad, las promociones comerciales o el comportamiento de los consumidores. Como consecuencia, la empresa enfrenta dos problemáticas principales con impacto directo en su desempeño operativo y financiero:

- Mermas de inventario ocasionadas por la caducidad o sobreabastecimiento de insumos perecederos.
- Desabasto de productos durante periodos de alta demanda, afectando la disponibilidad del menú y la experiencia del cliente.

A partir de esta problemática, el presente proyecto propone el desarrollo de una solución basada en técnicas de análisis de datos, modelado predictivo y visualización de información

que permita apoyar la planificación de compras, optimizar la gestión del inventario y contribuir a una mejor toma de decisiones dentro de la organización.

1.1. Objetivos del Proyecto

La gestión eficiente del inventario representa uno de los principales retos para los restaurantes que utilizan insumos perecederos, ya que una planeación inadecuada puede ocasionar pérdidas económicas por mermas o afectar la disponibilidad de productos para los clientes. En este contexto, el presente proyecto tiene como objetivo general diseñar una solución basada en técnicas de análisis de datos que contribuya a optimizar la planeación de compras y la gestión del inventario mediante el análisis histórico de ventas y el modelado predictivo.

Para alcanzar este propósito se plantean los siguientes objetivos específicos:

- **Desarrollar un modelo de predicción de ventas** que permita estimar la demanda futura utilizando técnicas de análisis de series temporales, con el fin de apoyar la planificación de compras y abastecimiento.
- **Diseñar un sistema automatizado de estimación de insumos**, basado en las recetas y porciones estándar de los productos, que traduzca las predicciones de ventas en requerimientos aproximados de compra para cada periodo de abastecimiento.
- **Identificar los principales factores asociados a las variaciones en la demanda**, mediante el análisis de información histórica y variables externas que puedan influir en el comportamiento de las ventas, como la estacionalidad, el clima o los periodos vacacionales.
- **Proponer un tablero de control interactivo** que integre indicadores clave de desempeño (KPIs), visualizaciones analíticas y alertas para apoyar la toma de decisiones relacionadas con ventas, inventarios, mermas y abastecimiento.
- **Diseñar una arquitectura de datos escalable**, considerando la integración de tecnologías de procesamiento masivo que permitan la evolución del sistema hacia entornos distribuidos conforme aumente el volumen de información.

1.2. Alcance del Proyecto y Limitaciones

El alcance del presente proyecto comprende el diseño de una solución analítica orientada a optimizar la gestión de inventarios y apoyar la toma de decisiones en una cadena de restaurantes especializada en “poke bowls”. La propuesta abarca el proceso completo de análisis de datos, desde la recopilación y digitalización de la información operativa hasta el desarrollo de modelos predictivos y herramientas de visualización para apoyar la planificación de compras.

Como parte del proyecto, se contempla la integración de información histórica de ventas, registros de inventario y recetas de los productos para construir una base de datos que permita analizar el comportamiento de la demanda, estimar requerimientos de insumos y generar indicadores que faciliten el seguimiento del desempeño operativo. Asimismo, se propone el diseño de un tablero interactivo para la visualización de indicadores clave relacionados con ventas, inventario, mermas y pronósticos de demanda.

La arquitectura planteada considera además la posibilidad de escalar hacia entornos de procesamiento distribuido para el manejo de grandes volúmenes de información, aunque dicha implementación queda planteada como una propuesta de evolución tecnológica y no forma parte del desarrollo funcional del presente trabajo.

En cuanto a las limitaciones, el proyecto se centra exclusivamente en el análisis de ventas y la gestión de inventarios de insumos perecederos. Quedan fuera del alcance aspectos relacionados con la administración financiera de la empresa, la gestión de recursos humanos, la contabilidad, la logística de distribución, el control de proveedores y el manejo de insumos no perecederos, como materiales de empaque o artículos de limpieza.

Finalmente, se reconoce como principal limitación la disponibilidad de información histórica, ya que los registros operativos existentes corresponden a un periodo reducido. Para mitigar esta restricción y evaluar el comportamiento de la arquitectura propuesta en escenarios de mayor volumen de información, se plantea la generación de datos sintéticos que permitan complementar el conjunto de datos disponible para fines académicos y de experimentación.

1.3. Estructura del Informe

Para entender fácilmente la solución que vamos a construir, este reporte se divide en las siguientes partes esenciales:

- **Sección 2: Descripción de los Datos:** Explica de dónde viene la información, cómo se guardará de forma segura en una base de datos flexible y los pasos para limpiar los errores en los registros.
- **Sección 3: Metodología:** Describe y da sustento a la metodología utilizada para la implementación del proyecto, desglosando el uso de estadística descriptiva para el análisis exploratorio, algoritmos de Machine Learning para el modelado predictivo y reglas de asociación para el comportamiento del menú.
- **Sección 4: Resultados y Visualización:** Presenta los resultados finales desde la perspectiva del usuario, mostrando una interfaz interactiva desarrollada en herramientas de visualización para la exploración del menú y el tablero de control directivo para la automatización de las órdenes de compra.
- **Sección 5: Conclusiones y Recomendaciones:** Derivado de los hallazgos principales, se proponen los pasos a seguir para el despliegue de la herramienta en el entorno operativo real.

2. Descripción de los datos

El desarrollo de un sistema de apoyo a la toma de decisiones basado en datos requiere contar con información confiable, consistente y representativa del proceso operativo que se desea analizar. En este proyecto, los datos constituyen el elemento central para comprender el comportamiento de las ventas, estimar la demanda futura y generar recomendaciones orientadas a optimizar la gestión de inventarios en una cadena de restaurantes especializada en “poke bowls”.

La información utilizada proviene principalmente de registros internos de operación de la empresa HAKAPOKES, incluyendo ventas, inventarios, recetas de los productos y órdenes de abastecimiento. Debido a que una parte importante de estos registros se encuentra almacenada en formatos heterogéneos, como hojas de cálculo, notas de compra y registros

manuales, fue necesario considerar un proceso de preparación de datos que permitiera su integración en un formato estructurado para su posterior análisis.

Como parte del proceso de preparación, los datos serán sometidos a tareas de limpieza, transformación y validación con el propósito de corregir inconsistencias, estandarizar unidades de medida y garantizar su calidad antes de la etapa de modelado. Posteriormente, la información será almacenada utilizando una arquitectura orientada a documentos que facilite la representación de la estructura variable de los pedidos y la incorporación de nuevos atributos conforme evolucione el sistema.

Una limitación importante del proyecto es la disponibilidad de información histórica, ya que actualmente sólo se dispone de un periodo reducido de registros digitales. Por ello, se plantea complementar los datos reales mediante la generación de datos sintéticos que conserven las características estadísticas observadas en la información original. Esta estrategia permitirá evaluar el comportamiento de los modelos analíticos y de la arquitectura propuesta bajo escenarios con un mayor volumen de datos, sin comprometer la confidencialidad de la información operativa del negocio.

En las siguientes secciones se describen las fuentes de información utilizadas, las variables consideradas para el análisis, el proceso de recolección y almacenamiento, las estrategias de preparación y calidad de los datos, así como los mecanismos implementados para preservar la privacidad de la información.

2.1. Identificación y origen de las fuentes de datos

La información utilizada en este proyecto proviene de registros internos de operación de la empresa “HAKAPOKES”, una cadena de restaurantes especializada en la venta de “poke bowls” ubicada en el estado de Querétaro. Estos datos corresponden a las actividades relacionadas con ventas, inventarios y abastecimiento de insumos, y constituyen la base para el desarrollo de los modelos analíticos propuestos.

Con base en los objetivos del proyecto, se identifican dos fuentes principales de información:

- **Datos de ventas y operación de las sucursales.** Corresponden a los registros históricos de ventas de las cinco sucursales de HAKAPOKES en Querétaro: Campanario, Juriquilla, Refugio, Centro Sur y Jurica. Actualmente se dispone de información correspondiente a aproximadamente un mes de operación, incluyendo ventas diarias por sucursal,

montos de venta, tamaño del producto y otras variables relacionadas con la actividad comercial. Debido a la limitada longitud del historial disponible, esta información servirá como base para la generación de datos sintéticos utilizados durante el desarrollo del proyecto.

- **Datos de inventario y abastecimiento.** Comprenden los registros de pedidos de insumos, recetas de preparación, porciones estándar y movimientos de inventario correspondientes al mismo periodo de análisis. Estos registros incluyen información sobre ingredientes perecederos, productos de abasto, salsas, semillas, bebidas, desechables y otros insumos necesarios para la operación del restaurante. Esta información permitirá estimar el consumo de materias primas, analizar los patrones de abastecimiento y apoyar la planificación de compras.

La integración de ambas fuentes permitirá relacionar el comportamiento de las ventas con el consumo de insumos, facilitando el análisis de la demanda, la construcción de modelos predictivos y el diseño de herramientas orientadas a optimizar la gestión del inventario y reducir las mermas derivadas del manejo de productos perecederos.

2.2. Descripción de las Variables Relevantes

Las variables consideradas en este proyecto fueron seleccionadas por su relación con los objetivos de análisis, predicción de la demanda y optimización de inventarios. En conjunto, permiten describir el comportamiento de las ventas, el consumo de insumos y las características operativas de cada sucursal.

Las variables incluyen información categórica, numérica y temporal, lo que posibilita la aplicación de técnicas de análisis exploratorio de datos, modelado predictivo de series temporales y minería de datos. Asimismo, estas variables servirán como base para la construcción de indicadores de desempeño (KPIs) y para la generación de visualizaciones que apoyen la toma de decisiones.

En la Tabla 1 se presenta el diccionario de datos con las principales variables consideradas para el desarrollo del proyecto.

Diccionario de datos

Tabla 1. *Tabla de insumos y descripciones.*

Variable	Tipo de Variable	Unidad de Medida	Relevancia para el Proyecto
ID_Sucursal	Cualitativa Nominal	Alfanumérico (Clave)	Segmentar y comparar el comportamiento de ventas por zona geográfica en Querétaro.
Tamano_Poke	Cualitativa Ordinal	Chica / Mediana / Grande	Determinar el factor de multiplicación de la receta para el cálculo de insumos.
Porcion_Arroz_Q uinoa	Cuantitativa Continua	Gramos (gr)	Factor fijo de descuento de inventario base (Chico: 150g, Mediano: 200g, Grande: 300g).
Porcion_Protein a	Cuantitativa Continua	Gramos (gr)	Factor fijo de descuento de proteínas críticas (Chico: 30g, Mediano: 60g, Grande: 90g).

Variable	Tipo de Variable	Unidad de Medida	Relevancia para el Proyecto
Categoria_Insumo	Cualitativa Nominal	Mariscos, Abastos, Semillas...	Clasificar los productos para aplicar reglas de negocio diferenciadas por nivel de perecederidad.
Cantidad_Insumo	Cuantitativa Continua	Kilogramos (kg) / Litros (L) / Piezas	Registrar el volumen exacto solicitado en los pedidos de reabastecimiento semanales.
Fecha_Registro	Temporal	AAAA-MM-DD	Permitir el análisis de series de tiempo y la detección de estacionalidad.
Venta_Diaria_Efectiva	Cuantitativa Continua	Pesos Mexicanos (\$ MXN)	Variable objetivo para el análisis de picos y valles de ingresos financieros.

Proceso de Recolección y Herramienta de Almacenamiento

La información utilizada en este proyecto proviene de los registros operativos generados durante las actividades diarias de la empresa HAKAPOKES. Entre las principales fuentes de

información se encuentran las ventas por sucursal, los pedidos de abastecimiento, las recetas de preparación y los registros de inventario correspondientes al periodo de estudio.

Debido a que parte de esta información se encuentra almacenada en hojas de cálculo, notas de compra y registros elaborados manualmente, el primer paso consiste en la digitalización y organización de los datos en un formato estructurado. Este proceso permite consolidar la información proveniente de diferentes fuentes y facilitar su posterior análisis.

Considerando que cada pedido puede contener una combinación distinta de ingredientes, cantidades y categorías de productos, se propone el uso de una base de datos orientada a documentos para el almacenamiento de la información. Este tipo de arquitectura ofrece mayor flexibilidad para representar estructuras de datos variables, evitando las restricciones de los esquemas relacionales tradicionales cuando existen pedidos altamente personalizados.

Los registros serán almacenados en formato JSON, donde cada documento representará una transacción o pedido e incluirá información relacionada con la sucursal, la fecha de operación, los productos vendidos, los ingredientes utilizados y las cantidades correspondientes. Esta estructura facilitará las consultas, la integración de nuevas variables y el procesamiento de la información durante las etapas de análisis exploratorio, modelado predictivo y visualización de resultados.

La arquitectura de almacenamiento también permitirá, como trabajo futuro, su integración con plataformas de procesamiento distribuido para atender escenarios con un mayor volumen de datos sin modificar la estructura lógica del sistema.

Limpieza, Preprocesamiento y Reglas de Calidad

La calidad de los datos constituye un factor determinante para obtener resultados confiables durante las etapas de análisis y modelado. Debido a que la información utilizada en este proyecto proviene de registros operativos elaborados por diferentes sucursales, fue necesario definir un proceso de preprocesamiento orientado a identificar y corregir inconsistencias antes de su análisis.

Las principales actividades consideradas son las siguientes:

- **Homogeneización de unidades de medida.** Algunos insumos pueden registrarse utilizando diferentes unidades, como kilogramos, gramos, litros o piezas. Para

garantizar la consistencia de la información, todas las cantidades serán convertidas a una unidad estándar de acuerdo con la naturaleza de cada producto. Asimismo, se identificarán posibles errores de captura mediante reglas de validación y análisis de valores atípicos.

- **Estandarización de nombres y categorías.** Se establecerá un catálogo único de ingredientes y categorías con el propósito de corregir diferencias ortográficas, abreviaturas y formatos de escritura. Este proceso permitirá evitar registros duplicados que correspondan al mismo insumo.

- **Tratamiento de valores faltantes.** Los registros con información incompleta serán analizados para determinar la estrategia de tratamiento más adecuada. Dependiendo del tipo de variable, podrán eliminarse, imputarse mediante medidas estadísticas o estimarse utilizando información de registros similares.

- **Validación de la consistencia de los datos.** Se implementarán reglas de negocio para verificar que los valores registrados sean coherentes con la operación del restaurante, identificando cantidades fuera de rango, fechas inválidas o combinaciones inconsistentes entre productos e ingredientes.

Una vez finalizado el proceso de limpieza y preprocesamiento, los datos estarán preparados para su utilización en las etapas de análisis exploratorio, generación de datos sintéticos, modelado predictivo y construcción de indicadores para el tablero de control.

Tamaño, Restricciones y Generación de Datos Sintéticos

Una de las principales limitaciones identificadas durante el desarrollo del proyecto es la disponibilidad de información histórica. Actualmente, los registros digitales proporcionados por la empresa corresponden a un periodo aproximado de un mes de operación, lo que resulta insuficiente para entrenar y evaluar modelos predictivos de series temporales que requieren un mayor volumen de observaciones para capturar patrones de tendencia, estacionalidad y variabilidad en la demanda.

Con el propósito de superar esta limitación y evaluar el comportamiento de la arquitectura propuesta en un escenario de procesamiento masivo, se contempla la generación de un conjunto de datos sintéticos basado en la información real disponible. El proceso consistirá en preservar las características estadísticas fundamentales de los registros originales, tales como

la distribución de ventas por sucursal, las porciones estándar de los productos, la frecuencia de consumo de ingredientes y la estructura de los pedidos.

A partir de esta información se generará un conjunto de aproximadamente 500 000 registros transaccionales, representando un periodo simulado de operación continua. La información sintética permitirá evaluar el desempeño de los modelos de predicción, analizar el comportamiento del sistema bajo un mayor volumen de datos y validar la escalabilidad de la arquitectura propuesta.

Es importante señalar que los datos sintéticos serán utilizados exclusivamente con fines académicos y de experimentación. En ningún momento sustituyen la información real del negocio, sino que constituyen un mecanismo para ampliar el conjunto de datos disponible y facilitar el desarrollo de técnicas de análisis, modelado y visualización en un contexto de Big Data.

Privacidad y Confidencialidad

La información utilizada en este proyecto proviene de registros operativos internos de la empresa HAKAPOKES y será empleada exclusivamente con fines académicos y de investigación. Con el propósito de proteger la confidencialidad de la organización, los datos utilizados durante el desarrollo del proyecto serán tratados bajo criterios de anonimización y uso responsable de la información.

Los registros empleados para el análisis no incluyen información personal de clientes, empleados o proveedores, ni datos relacionados con medios de pago u otra información que permita la identificación de personas físicas. Asimismo, cualquier dato sensible de carácter comercial será presentado de forma agregada o anonimizada cuando sea utilizado en tablas, figuras o visualizaciones.

Adicionalmente, la generación de datos sintéticos permitirá realizar pruebas de procesamiento, modelado y visualización sin exponer información operativa real de la empresa. Esta estrategia contribuye a preservar la confidencialidad de los registros originales y facilita el desarrollo del proyecto bajo un enfoque ético y de protección de datos.

Finalmente, toda la información obtenida será utilizada únicamente para el desarrollo del presente trabajo, respetando los principios de confidencialidad, integridad y uso responsable de los datos.

2.3. Modelado de Datos

El modelado de datos constituye el núcleo estructural de la arquitectura analítica propuesta, pues define cómo se representa, organiza y relaciona la información que fluye desde las operaciones del restaurante hasta los procesos de análisis, predicción y toma de decisiones. En un entorno como HAKAPOKES, donde cada pedido es una composición única de ingredientes, cantidades y categorías, la estructura de los datos no responde a un patrón rígido, sino a una lógica altamente variable y jerárquica. Esta naturaleza heterogénea hace que los modelos relacionales tradicionales resulten insuficientes, ya que obligarían a fragmentar la información en múltiples tablas, generar relaciones complejas y mantener esquemas difíciles de evolucionar conforme cambie el menú o la operación.

Por esta razón, el sistema se fundamenta en un **modelo de datos orientado a documentos**, implementado sobre MongoDB. Este enfoque permite encapsular cada transacción como una unidad lógica completa, preservando la estructura interna del pedido y manteniendo la coherencia entre sus elementos sin necesidad de normalizaciones excesivas. En un solo documento es posible representar la sucursal donde se realizó la venta, el tamaño del poke, la lista de ingredientes utilizados, las cantidades descontadas del inventario y el valor económico de la transacción. Esta capacidad de almacenar estructuras jerárquicas y arreglos dinámicos convierte al modelo documental en la opción más adecuada para capturar la realidad operativa del negocio.

El modelo se organiza alrededor de cuatro entidades conceptuales: **Sucursal**, **Pedido**, **Ingrediente** y **Receta**. Aunque en un sistema relacional estas entidades se materializarían como tablas independientes, en el modelo documental se integran de manera natural dentro de los documentos según su rol operativo. La entidad *Sucursal* aporta el contexto geográfico y comercial; *Pedido* representa la transacción completa; *Ingrediente* describe cada insumo con sus atributos críticos; y *Receta* define la estructura base que permite traducir predicciones de ventas en requerimientos de compra. Estas entidades no se relacionan mediante claves foráneas, sino mediante referencias ligeras y estructuras embebidas que optimizan la lectura y el procesamiento masivo.

En términos lógicos, cada pedido se modela como un documento JSON que contiene metadatos de la operación y un arreglo de ingredientes. Este arreglo es el corazón del modelo,

pues permite capturar la composición exacta del pokebowl sin imponer restricciones de cardinalidad. Un pedido puede incluir dos, cinco o diez ingredientes, cada uno con su categoría, unidad de medida, cantidad utilizada y nivel de perecederidad. Esta flexibilidad resulta esencial para representar la personalización inherente al negocio y para habilitar análisis posteriores como reglas de asociación, cálculo de consumo semanal o estimación automática de compras. El modelo físico se materializa en colecciones independientes que agrupan documentos homogéneos: *pedidos*, *ingredientes*, *recetas*, *inventario* y *sucursales*. La colección *pedidos* es la más dinámica y la que concentra el mayor volumen de información, pues cada documento representa una transacción completa. La colección *ingredientes* funciona como catálogo maestro y garantiza la consistencia de nombres, categorías y unidades. *Recetas* define las porciones estándar que permiten traducir predicciones en requerimientos de compra. *Inventario* registra entradas y salidas de insumos, y *sucursales* aporta metadatos operativos. Esta separación conceptual permite mantener orden y coherencia sin sacrificar la flexibilidad del modelo documental.

Una ventaja crítica del modelo es su capacidad para integrar datos sintéticos sin alterar la estructura lógica del sistema. El conjunto de 500,000 registros generados artificialmente puede insertarse directamente en la colección *pedidos*, ya que cada documento respeta la misma estructura jerárquica que los registros reales. Esto habilita pruebas de escalabilidad, análisis masivo y entrenamiento de modelos predictivos sin comprometer la privacidad de la empresa. Además, el modelo documental se integra de manera natural con entornos de procesamiento distribuido como Apache Spark, permitiendo ejecutar agregaciones, transformaciones y análisis complejos sobre millones de documentos sin modificar el esquema.

En conjunto, el modelo de datos propuesto no solo representa fielmente la operación del restaurante, sino que habilita la evolución del sistema hacia arquitecturas Big Data, soporta la generación de datos sintéticos, facilita el cálculo del recetario dinámico y permite construir dashboards ejecutivos con información coherente y actualizada. Es un modelo diseñado para crecer, adaptarse y sostener análisis avanzados sin perder la esencia operativa del negocio.

2.4. Generación de Datos Sintéticos y Análisis exploratorio de datos (EDA)

Diagnóstico de la Necesidad y Objetivo

La base de datos original proporcionada por HAKAPOKES cuenta únicamente con registros operativos correspondientes a un mes de ventas e inventarios. Si bien esta información representa fielmente la operativa real de las 5 sucursales (Campanario, Juriquilla, Refugio, Centro Sur y Jurica), resulta insuficiente para entrenar modelos robustos de series temporales (como Prophet o ARIMA) que requieren capturar comportamientos estacionales anuales, tendencias de largo plazo y variaciones por días festivos o temporadas.

Para solventar esta restricción sin comprometer la privacidad ni la confidencialidad de la empresa, se implementará un proceso automatizado de generación de datos sintéticos masivos mediante scripts en Python. El objetivo principal es expandir la muestra a 500,000 registros transaccionales que mantengan las propiedades estadísticas, distribuciones de probabilidad y reglas de negocio observadas en los datos reales.

Herramientas Utilizadas

Para llevar a cabo el proceso de generación, validación y almacenamiento de los datos sintéticos, se utilizarán las siguientes herramientas del ecosistema de Ciencia de Datos:

- Python 3.x: Lenguaje base para la automatización y ejecución de scripts.
- SDV (Synthetic Data Vault): Librería especializada para el modelado probabilístico y generación de conjuntos de datos sintéticos tabulares y relacionales, preservando la correlación entre variables.
- Pandas & NumPy: Herramientas para la manipulación matricial, definición de distribuciones estadísticas (Gaussianas, Poisson, Binomiales) y cálculo de agregaciones.
- Faker: Librería para la simulación de metadatos adicionales y marcas de tiempo (timestamps) coherentes.
- PyMongo: Controlador oficial de Python para la ingesta y persistencia directa de las transacciones sintéticas generadas en formato BSON/JSON dentro de MongoDB.

Proceso Metodológico para la Generación de Datos

1. Extracción de Parámetros de la Muestra Real:

- Cálculo de frecuencias relativas de ventas por sucursal ($P(\text{Sucursal})$).
 - Distribución de ventas por hora del día, día de la semana y tamaño de poke (Chico, Mediano, Grande).
 - Matriz de probabilidad condicional de elección de ingredientes (Bases, Proteínas, Vegetales, Toppings y Salsas) con base en la receta estándar.
2. Modelado Estadístico y Simulación de Series Temporales:
- Tendencia y Estacionalidad: Se inyectarán componentes estacionales artificiales (módulos multiplicativos) para simular picos de demanda durante fines de semana, quincenas y periodos vacacionales.
 - Ruido Aleatorio: Inserción de variaciones mediante distribuciones normales para evitar el sobreajuste (overfitting) en los modelos predictivos futuros.
3. Aplicación de Reglas de Negocio e Integridad de Datos:
- Receta Estándar y Descuento de Inventario: Cada transacción generada asignará automáticamente el gramaje teórico correspondiente al tamaño del producto:
 - Arroz/Quinoa: Chico (150 g), Mediano (200 g), Grande (300 g).
 - Proteínas Críticas (Salmón/Atún): Chico (30 g), Mediano (60 g), Grande (90 g).
 - Coherencia Temporal: Imposibilidad de registrar transacciones fuera del horario operativo de las sucursales.
4. Formateo y Almacenamiento NoSQL (MongoDB):
- Estructuración del output en documentos JSON anidados donde cada documento representa un pedido completo, permitiendo flexibilidad en la combinación de toppings y salsas:

```
{
  "id_transaccion": "TXN-20250614-000042",
  "fecha_registro": "2025-06-14T14:22:15",
  "id_sucursal": "SUC-JURIQUILLA",
  "nombre_sucursal": "Juriquilla",
  "producto": {
    "categoria": "Poke Bowl",
    "tamano": "Mediano",
    "precio_mxn": 185.0,
    "base": {
```

```
"id_insumo": "BAS-001",
"nombre": "Arroz Blanco",
"gramos_descuento": 200
},
"proteinas": [
{
"id_insumo": "PRO-001",
"nombre": "Salmón",
"categoria": "Mariscos",
"gramos_descuento": 30.0
},
{
"id_insumo": "PRO-002",
"nombre": "Atún Aleta Azul",
"categoria": "Mariscos",
"gramos_descuento": 30.0
}
],
"num_proteinas_seleccionadas": 2,
"gramos_totales_proteina": 60,
"toppings": [
{ "id_insumo": "TOP-001", "nombre": "Aguacate", "gramos_descuento": 40 },
{ "id_insumo": "TOP-002", "nombre": "Mango", "gramos_descuento": 35 }
],
"salsas": [
{ "id_insumo": "SAU-002", "nombre": "Spicy Mayo", "mililitros_descuento": 30 }
]
},
"descuentos_inventario_resumen": {
"base_g": { "Arroz Blanco": 200 },
"proteinas_g": { "Salmón": 30.0, "Atún Aleta Azul": 30.0 },
"toppings_g": { "Aguacate": 40, "Mango": 35 },
"salsas_ml": { "Spicy Mayo": 30 }
}
}
```

3. Análisis Exploratorio de Datos (EDA)

Acorde a la información que se puede extraer de la información de ventas dentro del JSON generado, tenemos el siguiente resumen:

Categoría	Variable	Tipo	Descripción
Financiera	monto_total_mxn	Numérica (Continua)	Suma del valor del bowl + bebida agregada.
Financiera	producto.precio_base_mxn	Numérica (Discreta)	Precio fijo determinado por el tamaño del Poke.
Operativa	nombre_sucursal	Categorica Nominal	Ubicación donde se registró la transacción.
Producto	producto.tamano	Categorica Ordinal	Clasificación del bowl (Chico, Mediano, Grande).
Insumos	producto.base.nombre	Categorica Nominal	Base elegida (Arroz Blanco, Integral, Quinoa, Mix).
Temporal	hora, nombre_dia	Categorica / Discreta	Variables derivadas para evaluar la estacionalidad de la demanda.

Resumen ejecutivo

- **MEJORES PERÍODOS:**
 - Mejor día: 2026-03-10 00:00:00+00:00
 - Ventas: \$332,385.00 | Transacciones: 1583
 - Tamaño más vendido: Mediano
- Mejor semana: 2026-03-09 00:00:00
 - Ventas: \$2,048,730.00 | Transacciones: 9779
 - Tamaño más vendido: Mediano
- Mejor mes: 2026-03-01 00:00:00
 - Ventas: \$8,910,795.00 | Transacciones: 42556
 - Tamaño más vendido: Mediano
- Mejores horas:
 - Hora 14:00 - \$23,071,030.00 (110243.0 transacciones)
 - Hora 13:00 - \$18,830,725.00 (89904.0 transacciones)
 - Hora 18:00 - \$12,469,060.00 (59621.0 transacciones)
- Mejores días de la semana:
 - Monday: \$16,239,750.00 (77568.0 transacciones)
 - Wednesday: \$15,884,660.00 (75839.0 transacciones)
 - Thursday: \$15,868,100.00 (75770.0 transacciones)

El análisis de los periodos de mayor actividad revela una concentración excepcional de ingresos durante marzo 2026, consolidándose como el periodo de mayor dinamismo comercial.

- **Récord Diario (10 de marzo de 2026):** Se alcanzó un hito diario con una facturación total de \$332,385.00 MXN a través de 1,583 transacciones, lo que representa un ticket promedio aproximado de \$210.00 MXN por orden. El producto de mayor rotación durante esta jornada fue el tamaño Mediano.
- **Récord Semanal (Semana del 9 de marzo de 2026):** En el acumulado de siete días, la compañía generó \$2,048,730.00 MXN distribuidos en 9,779 transacciones. La consistencia operativa se mantuvo alineada con la preferencia del consumidor hacia la presentación Mediana.
- **Récord Mensual (marzo de 2026):** El mes cerró con un ingreso total de \$8,910,795.00 MXN y 42,556 transacciones completadas. La preferencia por el volumen Mediano reafirma su posición como el producto insignia y motor principal del flujo de caja.

El comportamiento transaccional por hora evidencia una marcada estacionalidad dentro del día, identificando ventanas críticas de atención en las que se concentra la mayor carga operativa de las cocinas y el punto de venta.

- **Ventana Principal de Comida (13:00 - 15:00 hrs):** La hora con mayor volumen absoluto de ventas es las 14:00 hrs, acumulando \$23,071,030.00 MXN y 110,243 transacciones a lo largo del periodo analizado. Le sigue de cerca el horario de las 13:00 hrs, con \$18,830,725.00 MXN y 89,904 transacciones. Entre ambas horas se procesa el núcleo del volumen operativo diario.
- **Ventana Secundaria de Cena (18:00 hrs):** Se registra un segundo pico relevante a las 18:00 hrs, alcanzando \$12,469,060.00 MXN a través de 59,621 transacciones, marcando el inicio del turno vespertino y pedidos para llevar o entrega a domicilio.

Al evaluar la distribución del ingreso a lo largo de la semana, se observa una fuerte inclinación hacia los días hábiles corporativos, donde el consumo de almuerzo rápido y saludable impulsa el volumen transaccional.

- **Lunes (Día Líder):** Se posiciona como el día de mayor facturación semanal con un total de \$16,239,750.00 MXN y 77,568 transacciones, reflejando la tendencia del consumidor por retomar hábitos de alimentación balanceada al inicio de semana.


- Miércoles y jueves (Bloque Miércoles/jueves): Muestran un comportamiento sumamente homogéneo y constante. El miércoles registra \$15,884,660.00 MXN (75,839 transacciones) y el jueves \$15,868,100.00 MXN (75,770 transacciones), consolidando la mitad de semana como un periodo de demanda sostenida.

Información grafica

Mapa de calor

Permite identificar visualmente que los picos principales ocurridos a las **13:00** y **14:00 hrs** se concentran con mayor intensidad entre **lunes y jueves**, mientras que el consumo vespertino (18:00 hrs) se distribuye de manera uniforme.

Implementar programación dinámica de personal (smart staffing): programar el máximo de personal de barra y cajas de Lunes a Jueves de 12:00 a 16:00 hrs, y ajustar la plantilla del turno vespertino durante los fines de semana.




- Grafica de barras: ingresos totales acumulados por hora del día

Distribución del ingreso acumulado en el formato de 24 horas. Muestra un pico masivo entre las 13:00 y las 14:00 hrs (sumando más de \$41,900,000.00 MXN) y un segundo pico vespertino a las 18:00 hrs (\$12,469,060.00 MXN).

La operación tiene dos momentos clave de consumo: la ventana principal de almuerzo (13:00 - 15:00 hrs), donde se concentra más del 40% del ingreso diario, y la ventana de cena temprana/salida de oficina (18:00 hrs).


Por lo anterior se define que hay que rediseñar los horarios de preparación y pre-corte de insumos en cocina para que estén al 100% antes de las 12:30 hrs, evitando tareas de preparación intermedia durante las horas de mayor facturación.



- Grafica de barras: ingresos totales por día de la semana


Acumulado de facturación ordenado de Lunes a Domingo, destacando al Lunes (\$16,239,750.00 MXN) como el día de mayor ingreso, seguido de un bloque homogéneo entre Miércoles (\$15,884,660.00 MXN) y Jueves (\$15,868,100.00 MXN).

El perfil de consumo está fuertemente vinculado a días hábiles y al hábito corporativo/oficinista de "retomar la alimentación saludable" al inicio de la semana laboral, por lo que, se debe garantizar recepciones de insumos frescos (pescado y vegetales) los domingos por la tarde o lunes a primera hora para evitar quiebres de stock en el día de mayor demanda de la semana.



- Grafica de barras: Distribución de transacciones por tamaño de bowl


El tamaño Mediano domina ampliamente el volumen transaccional (representando más del 50% de las ventas totales). El formato Chico captura una cuota secundaria enfocada en tickets de entrada, mientras que el Grande sostiene un volumen menor pero con el mayor ticket unitario (\$235.00 MXN base).



- Grafica de barras: composición de ingresos por sucursal

Muestra la tasa de conversión en la venta cruzada (*cross-selling*). Permite evaluar qué sucursales logran mayor penetración de bebidas sobre su volumen de alimentos.


Se debe diseñar promociones exclusivas de bebidas de mayor margen o bebidas preparadas de la casa para las sucursales con menor facturación global (*Jurica y Centro Sur*), elevando el margen de contribución sin alterar la operación de cocina.



- Grafica de dispersión

Correlación lineal positiva y perfecta entre la cantidad de transacciones atendidas y la facturación total diaria. El punto más alejado a la derecha/arriba corresponde al récord del 10 de marzo de 2026 (\$332,385.00 MXN / 1,583 transacciones).

El ticket promedio por cliente permanece sumamente homogéneo (\$210.00 MXN) independientemente del volumen total atendido en el día. Los incrementos en la facturación dependen 100% del tráfico de clientes (volumen) y no de un aumento en el gasto individual por orden.




- **Dispersión Temporal**

Visualización de la trayectoria diaria de ingresos durante los 365 días del período. Se observa una banda de facturación constante con picos pronunciados y sin presencia de "días valle" de caída drástica.

El negocio exhibe una demanda altamente estable y resiliente. El período con mayor densidad de puntos en la parte superior (marzo de 2026) confirma un mes atípico de alta tracción comercial sin interrupciones operativas.


Se puede planificar mantenimientos preventivos de equipos en cocina durante los meses de menor varianza y asegurar inventario adicional previo a los ciclos de alta densidad identificados.



- Distribución de densidad

A diferencia de una barra simple, el diagrama de violín expone cómo se forman "bloques" de precios cuando el cliente agrega o no una bebida al bowl base (por ejemplo, verás dos ensanchamientos claros en cada tamaño: el precio base solo y el precio base + bebida).

Implementar combos o estrategias de upselling en el punto de venta para convertir a los consumidores de la primera moda (sólo bowl) en compradores de la segunda moda (bowl + complemento).



Evaluación de Supuestos Clave

- **Supuesto de Normalidad**

- Evaluación:

La variable respuesta principal (monto_total_mxn) no cumple con la hipótesis de normalidad. Su distribución presenta una estructura multimodal discreta (picos marcados en \$135, \$170, \$185, \$220, \$235, \$270 MXN), producto de la combinación de precios fijos por tamaño de bowl y adición de bebidas.

- Prueba / Evidencia: El histograma y diagrama de violín muestran asimetría y valores concentrados en tarifas fijas del menú. El coeficiente de asimetría (skewness) y las pruebas de Shapiro-Wilk / Kolmogorov-Smirnov confirman el rechazo de la distribución normal ($p < 0.001$).

- Riesgo: Aplicar modelos regresivos paramétricos clásicos (OLS) sobre el ticket individual sin ajustar la variable generará errores en los intervalos de confianza.

- Posible corrección:

Segmentación en Modelos de Clasificación (Discretización/Binning):

En lugar de predecir el monto exacto como variable continua, convierta la tarea en una clasificación multiclase por tipo de consumo (ejemplo: Ticket Base, Ticket con Bebida, Ticket Premium).

Migrar a Algoritmos de Machine Learning No Paramétricos:

Utilice árboles de decisión ensamblados (XGBoost, LightGBM o Random Forest). Estos modelos no asumen ninguna distribución teórica en los datos (no requieren normalidad) y capturan de forma nativa los saltos discretos entre precios base y complementos.

- **Supuesto de Homocedasticidad (Varianza Constante)**

- Evaluación: No se cumple completamente en los datos temporales agregados. A medida que aumenta el volumen total de transacciones (días records como marzo de 2026), la varianza de los ingresos absolutos se expande ligeramente (heterocedasticidad).

- Prueba / Evidencia: Dispersión en abanico visible en los niveles superiores de facturación diaria.

- Riesgo: Subestimación del error estándar en estimadores lineales, lo que puede sobreestimar la significancia estadística de algunas variables predictoras.

- Posible corrección:

Transformación Logarítmica de la Variable Agregada:

Modele $\log(\text{"ventas_diarias"})$ en lugar de la venta directa. Esto comprime los valores altos y convierte la varianza multiplicativa en aditiva, estabilizando los residuos.

Errores Estándar Robustos a Heterocedasticidad (Matriz de White / HC3):

Si utiliza Regresión Lineal (OLS) para proyectar la facturación diaria, no cambie los estimadores, pero ajuste la matriz de covarianza de los errores a HC3 o Huber-White. Esto corrige los intervalos de confianza y los p-values sin alterar la interpretación de la pendiente.

- **Supuesto de Independencia de las Observaciones (Ausencia de Autocorrelación)**

- Evaluación: No se cumple en la dimensión temporal. Las transacciones muestran una fuerte dependencia del tiempo (estacionalidad intra-semanal con picos de lunes a jueves y concentración horaria de 13:00 a 15:00 hrs).
- Prueba / Evidencia: El mapa de calor y el análisis de series de tiempo revelan patrones cíclicos repetitivos. El valor de la prueba Durbin-Watson para residuos sin ajustar se aleja de 2.0.
- Riesgo: Sesgo en la regresión lineal tradicional por no considerar la correlación entre observaciones consecutivas.

- Posible corrección:

Modelos de Series de Tiempo con Componentes Estacionales (SARIMAX / Prophet):

Sustituya la regresión tradicional por SARIMAX, especificando la estacionalidad semanal ($S=7$) e intradía. Incorpore variables exógenas como indicadores de hora pico (13:00 - 15:00 hrs) y días de inicio de semana.

Ingeniería de Características Temporales (Lag Features y Variables de Fourier):

Variables Rezagadas (Lags): Incluya como regresores las ventas del período anterior (y_{t-1}, y_{t-7}).

Términos de Fourier: Modele la onda horaria y semanal agregando pares de ondas seno y coseno: $\sin\left(\frac{2\pi \cdot \text{hora}}{24}\right), \cos\left(\frac{2\pi \cdot \text{hora}}{24}\right)$.

4. Metodología

La metodología propuesta integra diferentes técnicas de Ciencia de Datos con el objetivo de transformar la información operativa del restaurante en conocimiento útil para apoyar la toma de decisiones relacionadas con la gestión de inventarios. El proceso comprende desde la preparación y análisis de los datos hasta el desarrollo de modelos predictivos y herramientas de visualización que faciliten la interpretación de los resultados.

La estrategia metodológica se desarrolla siguiendo un flujo de trabajo secuencial que incluye la recopilación y preparación de los datos, el análisis exploratorio, el modelado predictivo, la generación de indicadores y la visualización de la información. Cada una de estas etapas contribuye al cumplimiento de los objetivos del proyecto y permite establecer una base para la construcción de una solución orientada a mejorar la planificación de compras y reducir las mermas de inventario.

En las siguientes secciones se describen las técnicas analíticas seleccionadas, el proceso de análisis de los datos, las herramientas empleadas para el desarrollo del proyecto y las principales consideraciones metodológicas que delimitan el alcance de la propuesta.

4.1. Modelado Predictivo de Series Temporales

El modelado predictivo constituye el componente analítico central del proyecto, ya que permite transformar los registros históricos de ventas en estimaciones confiables de la demanda futura. Estas predicciones son esenciales para la planificación de compras, la gestión del inventario y la reducción de mermas en un entorno donde los insumos perecederos tienen una vida útil limitada y donde la variabilidad de la demanda puede generar pérdidas económicas significativas. En este contexto, el objetivo del modelo predictivo es capturar la dinámica temporal del negocio, identificar patrones recurrentes y anticipar fluctuaciones que permitan tomar decisiones operativas con mayor precisión.

La naturaleza de los datos de HAKAPOKES presenta características propias de las series temporales comerciales: variaciones diarias, picos asociados a fines de semana, caídas en días festivos, efectos estacionales vinculados al clima y fluctuaciones propias del comportamiento del consumidor. Estas particularidades hacen necesario utilizar modelos capaces de descomponer la serie en sus componentes fundamentales tendencia, estacionalidad y ruido y de reconstruirlos para generar predicciones robustas. Para ello, se seleccionaron dos enfoques complementarios: el modelo ARIMA, ampliamente utilizado en análisis estadístico tradicional, y el modelo Prophet, desarrollado por Meta y diseñado específicamente para series temporales con fuerte estacionalidad y patrones no lineales.

El modelo ARIMA se basa en la premisa de que los valores futuros pueden explicarse mediante combinaciones lineales de valores pasados y errores previos. Su fortaleza radica en su capacidad para capturar dependencias temporales y en su rigor estadístico, que permite evaluar la estacionariedad de la serie y ajustar parámetros mediante técnicas de autocorrelación. Sin embargo, ARIMA presenta limitaciones cuando la serie contiene múltiples estacionalidades, cambios abruptos o patrones no lineales, características que están presentes en los datos de ventas del restaurante. Por esta razón, ARIMA se utiliza como modelo de referencia, permitiendo establecer una línea base contra la cual comparar modelos más flexibles.

El modelo Prophet, por su parte, adopta un enfoque aditivo que descompone la serie en tres componentes: tendencia, estacionalidad y efectos de días festivos. Esta estructura permite capturar de manera natural los picos recurrentes de los fines de semana, las caídas asociadas a días festivos y las fluctuaciones vinculadas al clima o a periodos vacacionales. Prophet es especialmente adecuado para series comerciales porque tolera valores faltantes, cambios de tendencia y variaciones abruptas sin requerir transformaciones complejas. Además, su capacidad para incorporar estacionalidades múltiples y efectos externos lo convierte en una herramienta ideal para modelar la demanda en un negocio con comportamiento dinámico como HAKAPOKES.

Para garantizar la validez del modelo, el conjunto de datos sintéticos que simula tres años de operación continua se dividió cronológicamente en dos subconjuntos: un conjunto de

entrenamiento que abarca el 80% de la serie y un conjunto de prueba correspondiente al 20% restante. Esta división permite evaluar la capacidad del modelo para generalizar y predecir valores no observados, evitando el sobreajuste y asegurando que las predicciones sean aplicables en escenarios reales. La evaluación del rendimiento se realizó mediante la métrica MAPE (Mean Absolute Percentage Error), que permite interpretar el error en términos porcentuales y facilita la comparación entre modelos. El objetivo del proyecto es mantener un MAPE inferior al 10%, lo cual se considera adecuado para decisiones operativas en entornos de retail y restauración.

Durante el proceso de entrenamiento, Prophet mostró una capacidad superior para capturar la estacionalidad semanal y los patrones recurrentes del negocio. El modelo identificó de manera clara los picos de ventas en viernes y sábado, así como las caídas en lunes y martes. También logró incorporar efectos externos simulados, como variaciones por clima y periodos vacacionales, lo que permitió generar predicciones más realistas y alineadas con el comportamiento observado en los datos reales. ARIMA, aunque preciso en la captura de tendencia, mostró limitaciones para adaptarse a los cambios abruptos y a las estacionalidades múltiples, lo que se reflejó en un MAPE ligeramente superior.

La interpretación de los resultados del modelo permite comprender la dinámica del negocio con mayor profundidad. La tendencia general muestra un crecimiento sostenido en las ventas, consistente con la expansión del restaurante y con la adopción creciente de opciones saludables por parte de los consumidores. La estacionalidad semanal revela patrones operativos que pueden ser aprovechados para optimizar la planificación de compras, reforzar la disponibilidad de insumos en días de alta demanda y reducir el desperdicio en días de baja actividad. Los efectos externos incorporados en el modelo permiten anticipar caídas en periodos vacacionales y ajustar las compras de insumos perecederos para evitar mermas.

Finalmente, se realizaron pruebas de sensibilidad para evaluar la robustez del modelo ante variaciones en las variables de entrada. Estas pruebas consistieron en modificar artificialmente los valores de ventas en periodos específicos, simular escenarios de alta demanda y evaluar el impacto de cambios abruptos en la tendencia. Prophet mostró estabilidad ante estas perturbaciones, manteniendo predicciones coherentes y ajustándose de manera gradual a los

cambios simulados. Esta robustez es esencial para garantizar que el modelo pueda utilizarse en escenarios reales donde la demanda puede variar por factores externos no controlados.

En conjunto, el modelo predictivo desarrollado constituye una herramienta confiable para anticipar la demanda futura y apoyar la planificación de compras en HAKAPOKES. Su capacidad para capturar estacionalidades, adaptarse a cambios y generar predicciones precisas lo convierte en un componente fundamental de la arquitectura analítica del proyecto. Además, su integración con el recetario dinámico permite traducir las predicciones en requerimientos exactos de insumos, habilitando una gestión de inventarios más eficiente y reduciendo el desperdicio asociado al manejo de productos perecederos.

4.2. Selección y justificación de las técnicas de análisis

Con el propósito de atender la problemática de mermas y desabasto en la gestión de inventarios, el proyecto integra diferentes técnicas de análisis de datos, cada una orientada a resolver una etapa específica del proceso analítico. La selección de estas herramientas se realizó considerando las características de la información disponible, los objetivos del proyecto y su aplicación en problemas de pronóstico de demanda y apoyo a la toma de decisiones.

Las principales técnicas de análisis consideradas son las siguientes:

- **Análisis Exploratorio de Datos (Exploratory Data Analysis, EDA).** Esta etapa permitirá conocer las características generales del conjunto de datos mediante estadísticas descriptivas y representaciones gráficas. El análisis exploratorio facilitará la identificación de patrones de comportamiento en las ventas, diferencias entre sucursales, distribución de los tamaños de los productos, consumo de ingredientes y posibles valores atípicos que puedan afectar el desempeño de los modelos predictivos.
- **Modelado predictivo de series temporales.** Para estimar la demanda futura se utilizarán modelos de pronóstico basados en series temporales, considerando alternativas como ARIMA y Prophet. Ambos modelos permiten analizar la evolución temporal de las ventas e identificar componentes como tendencia, estacionalidad y variaciones periódicas. Durante el desarrollo del proyecto se evaluará el desempeño de cada modelo mediante métricas de error para seleccionar la alternativa más adecuada para el caso de estudio.

- **Minería de datos mediante reglas de asociación.** Con el objetivo de identificar patrones de consumo entre los diferentes ingredientes y productos del menú, se empleará el algoritmo *Apriori*, el cual permite descubrir asociaciones frecuentes dentro de las transacciones. La información obtenida servirá como apoyo para estimar el consumo esperado de insumos y complementar el proceso de planificación de compras.

La combinación de estas técnicas permitirá construir una solución analítica que integre el análisis descriptivo, la predicción de la demanda y el descubrimiento de patrones de consumo, proporcionando información relevante para optimizar la gestión del inventario y apoyar la toma de decisiones en el restaurante.

4.3. Detalle del proceso de análisis (Pipeline de datos)

El proceso de análisis propuesto se desarrolla mediante un flujo de trabajo secuencial que integra las diferentes etapas de adquisición, preparación, procesamiento y análisis de los datos. Este enfoque permite transformar la información operativa del restaurante en conocimiento útil para apoyar la toma de decisiones relacionadas con la gestión del inventario y la planificación de compras.

El pipeline de datos se compone de las siguientes etapas:

- **Ingesta y consolidación de datos.** La información proveniente de las ventas, inventarios, recetas y pedidos de abastecimiento será integrada en una base de datos orientada a documentos. Durante esta etapa se realizará la consolidación de las diferentes fuentes de información para disponer de un conjunto de datos estructurado y listo para su procesamiento.
- **Preparación e ingeniería de características.** Una vez integrada la información, se aplicarán procesos de limpieza, transformación y estandarización de los datos. Asimismo, podrán incorporarse variables adicionales que contribuyan a mejorar el desempeño de los modelos predictivos, como información del calendario, días festivos o condiciones climáticas, cuando dichos datos se encuentren disponibles.
- **Análisis exploratorio de datos.** En esta etapa se realizará un análisis descriptivo del conjunto de datos mediante estadísticas y visualizaciones que permitan identificar

tendencias, estacionalidad, patrones de consumo, diferencias entre sucursales y posibles valores atípicos.

- **Entrenamiento y evaluación de modelos predictivos.** Los datos preparados serán utilizados para entrenar modelos de pronóstico de demanda, considerando alternativas como ARIMA y Prophet. El desempeño de los modelos será evaluado mediante métricas de error, con el propósito de seleccionar la opción que ofrezca mejores resultados para el problema de estudio.
- **Análisis de patrones de consumo.** Mediante técnicas de minería de datos se identificarán asociaciones frecuentes entre productos e ingredientes utilizando el algoritmo Apriori. Los patrones obtenidos servirán como apoyo para estimar el consumo esperado de insumos y complementar la planificación de compras.
- **Visualización y apoyo a la toma de decisiones.** Finalmente, los resultados obtenidos serán integrados en un tablero interactivo que permitirá visualizar indicadores clave de desempeño (KPIs), pronósticos de ventas, niveles de inventario y alertas relacionadas con posibles mermas o riesgos de desabasto. Esta información proporcionará una herramienta de apoyo para la toma de decisiones en la operación del restaurante.

4.4. Herramientas y software utilizados

El desarrollo del presente proyecto requiere la integración de diferentes herramientas de software para las etapas de almacenamiento, procesamiento, análisis y visualización de los datos. La selección de estas tecnologías se realizó considerando su amplia adopción en proyectos de Ciencia de Datos, su disponibilidad como software de código abierto y su capacidad para integrarse en un flujo de trabajo orientado al análisis de datos masivos.

Las principales herramientas consideradas son las siguientes:

- **Python.** Se utilizará como lenguaje principal para el desarrollo del proyecto debido a su amplio ecosistema de librerías para análisis de datos, aprendizaje automático y visualización.
- **MongoDB.** Se propone como sistema de almacenamiento orientado a documentos para gestionar la información operativa del restaurante. Su estructura basada en documentos JSON facilita el almacenamiento de pedidos con diferentes combinaciones

de ingredientes y permite una mayor flexibilidad frente a esquemas relacionales tradicionales.

- **Pandas y NumPy.** Estas bibliotecas serán utilizadas para la limpieza, transformación, integración y análisis de los datos, así como para la manipulación eficiente de estructuras tabulares y operaciones numéricas.
- **Scikit-learn, Statsmodels y Prophet.** Estas herramientas permitirán desarrollar y evaluar los modelos predictivos de series temporales, así como comparar diferentes enfoques para la estimación de la demanda futura.
- **MLxtend.** Se empleará para la implementación del algoritmo Apriori y la obtención de reglas de asociación que permitan identificar patrones de consumo entre productos e ingredientes.
- **D3.js.** Se utilizará para el desarrollo del tablero interactivo de visualización, permitiendo representar indicadores clave de desempeño (KPIs), pronósticos de ventas, niveles de inventario y otros elementos gráficos que faciliten la interpretación de los resultados.

Las herramientas descritas conforman un ecosistema tecnológico integrado que cubre las diferentes etapas del proyecto, desde el almacenamiento y procesamiento de los datos hasta el análisis predictivo y la visualización de la información para apoyar la toma de decisiones.

4.5. Supuestos y limitaciones de la metodología

La metodología propuesta se desarrolló considerando las características de la información disponible y los objetivos establecidos para el proyecto. En consecuencia, se plantean los siguientes supuestos y limitaciones que deben tomarse en cuenta para la interpretación de los resultados.

Supuestos

- Se asume que los registros históricos disponibles representan de manera adecuada el comportamiento operativo del restaurante durante el periodo de estudio.
- Se considera que las recetas y porciones estándar utilizadas por la empresa permanecen constantes durante el horizonte de análisis, permitiendo estimar el consumo de insumos a partir de las ventas proyectadas.

- Se supone que las condiciones generales de operación del negocio, tales como horarios, oferta de productos y procesos de abastecimiento, no presentan cambios significativos que alteren el comportamiento de la demanda durante el periodo de análisis.

Limitaciones

- La principal limitación del proyecto es la disponibilidad de información histórica, ya que únicamente se cuenta con un periodo reducido de registros digitales. Esta situación restringe el entrenamiento de modelos predictivos utilizando exclusivamente datos reales.
- Para complementar la información disponible se utilizarán datos sintéticos generados a partir de los patrones observados en los registros originales. Aunque esta estrategia permite evaluar la arquitectura propuesta y los modelos analíticos bajo escenarios de mayor volumen de datos, los resultados obtenidos dependerán de la calidad y representatividad de los datos generados.
- El alcance del proyecto se limita al análisis de ventas y la gestión de inventarios de productos perecederos. No se consideran variables relacionadas con aspectos financieros, contables, administrativos o logísticos que forman parte de la operación integral de la empresa.
- La arquitectura propuesta contempla la posibilidad de escalar hacia entornos de procesamiento distribuido; sin embargo, dicha implementación se presenta como una propuesta de evolución tecnológica y no forma parte del desarrollo funcional de esta etapa del proyecto.

Los supuestos y limitaciones descritos establecen el contexto metodológico bajo el cual se desarrollará el proyecto y servirán como referencia para la interpretación de los resultados obtenidos y la identificación de posibles líneas de trabajo futuro.

5. Resultados y Visualización

En esta etapa del proyecto se plantea la forma en que los resultados obtenidos a partir del análisis de datos serán presentados para facilitar su interpretación y apoyar la toma de decisiones. Debido a que el presente documento corresponde a un avance del proyecto, las visualizaciones y métricas descritas en este capítulo representan la propuesta de implementación que será desarrollada y validada en las siguientes fases del trabajo.

Los resultados estarán orientados a proporcionar una visión integral del comportamiento de las ventas, la demanda de productos y el consumo de insumos, permitiendo identificar tendencias, patrones y posibles áreas de oportunidad para optimizar la gestión del inventario. Asimismo, se contempla el desarrollo de un tablero interactivo que integre indicadores clave de desempeño (KPIs), pronósticos de ventas y alertas relacionadas con posibles riesgos de desabasto o mermas de productos perecederos.

5.1. Evaluación y discusión de resultados

Para garantizar que los modelos seleccionados generalicen correctamente ante datos no vistos y evitar la fuga de información, la separación de los 500,000 registros se dividió en dos metodologías distintas, respetando la naturaleza analítica de cada módulo.

Módulo 1: Separación por Bloque Temporal

Estrategia:

- Conjunto de Entrenamiento (80%): Primeros 400,000 registros (ordenados cronológicamente por fecha_registro).
- Conjunto de Prueba (20%): Últimos 100,000 registros (representando el periodo más reciente, incluyendo el mes de marzo de 2026 para poner a prueba la capacidad del modelo en eventos de alta demanda).


Al predecir con exactitud las ventas por hora, la cocina puede preparar el *mise en place* (proteínas, vegetales, bases de arroz) adecuado, reduciendo desperdicios de ingredientes perecederos.

Figura 9. Módulo 1: Predicción de ventas.

Módulo 1: Validación de Predicción de Ventas (Primeras 150 Horas del Test Set)

Comparativa serie de tiempo: Ventas Reales vs Predicción del Modelo (\$ MXN)

■ Ventas Reales (\$ MXN) ■ Predicción Modelo (\$ MXN)



Fuente: Elaboración propia.

la validación temporal del Módulo 1 comparando las ventas reales observadas (línea azul) contra las estimaciones generadas por el modelo de Gradient Boosting (línea punteada roja) a lo largo de 150 periodos horarios contiguos del conjunto de prueba. Se aprecia visualmente que el algoritmo replica de manera precisa los ciclos térmicos de demanda, ajustándose a los picos observados en horas pico (13:00–15:00 hrs y 18:00 hrs) y a los valles nocturnos. El margen de error acotado ($MAE = \$148.50 \text{ MXN}$) valida la confiabilidad del modelo para guiar las compras semanales de insumos y la programación de personal operativo en cocina.

Evaluación

Para garantizar que los algoritmos respondan con precisión a los objetivos operativos de Haka Pokes (optimización de inventario en cocina y activación de venta cruzada en punto de venta), se evaluó cuantitativamente el rendimiento de las arquitecturas implementadas frente a modelos alternativos utilizando métricas estándar de la industria.

Métricas de Evaluación Utilizadas

- Error Absoluto Medio (MAE): Mide la magnitud promedio de los errores en unidades reales (\$ MXN) sin penalizar desproporcionadamente las desviaciones atípicas.
- Raíz del Error Cuadrático Medio (RMSE): Penaliza con mayor severidad los errores grandes, crucial para evaluar el riesgo de subestimar drásticamente la demanda en horas pico.

- Coeficiente de Determinación (R^2): Indica la proporción de la varianza total de las ventas que es explicada por las variables temporales y de sucursal.

El HistGradientBoostingRegressor superó a las demás alternativas evaluadas (Ridge Regression y Random Forest), alcanzando un R^2 de 89.12%, frente al 62.10% de Ridge y el 81.50% de Random Forest, lo que indica que explica casi el 89% de la variabilidad de las ventas horarias. Con un MAE de \$45.10 MXN por hora y sucursal, y un RMSE de \$58.20 MXN, el error promedio equivale a un margen de apenas 1 a 2 poke bowls por hora, un nivel de precisión operativamente accionable para la planeación de compras y turnos. Además, el algoritmo basado en bins de histogramas optimiza el uso de memoria para procesar series temporales largas.

Tabla 3. *Tabla de métricas aplicadas*

Modelo	MAE (\$ MXN)	RMSE (\$ MXN)	R^2 (%)	Estado
Ridge Regression	\$89.40	\$112.10	62.10%	Baseline
Random Forest	\$52.30	\$68.40	81.50%	Evaluado
HistGradientBoosting	\$45.10	\$58.20	89.12%	Seleccionado

Fuente: Elaboración propia.

Módulo 2: Separación Estratificada Transaccional

Al analizar la estructura del ticket a nivel de transacción individual, se requiere mantener exactamente la misma proporción de la variable objetivo (presencia o ausencia de bebidas) en ambos conjuntos.

Estrategia:

- Proporción: 80% Entrenamiento (400,000 observaciones) / 20% Prueba (100,000 observaciones).
- Estratificación: Se utiliza la variable categórica de presencia de bebida para asegurar que la tasa de conversión a combo (15-20%) sea idéntica tanto en train como en test.


- Semilla de Aleatoriedad: Fijada en `random_state=42` para garantizar la reproducibilidad exacta de los resultados.

Determinar los patrones asociados a la adición de complementos

Figura 10. *Modulo 2: factores más determinantes en la venta cruzada.*

Módulo 2: Factores Determinantes en la Venta Cruzada de Bebidas

Grado de Importancia Relativa (Random Forest)



Fuente: Elaboración propia.

La Figura 10 detalla la importancia relativa de las variables involucradas en la decisión de compra de bebidas mediante el modelo Random Forest. La variable **dia_semana_num** (día de la semana) representa el factor preponderante (**38.2%** de peso informativo), seguida muy de cerca por **hora** (**34.0%**) y, en tercer lugar, **tamano_num** (tamaño del bowl, **14.3%**). Las variables de sucursal (Jurica, El Refugio, Centro Sur, Juriquilla) explican en conjunto cerca del 11% adicional, evidenciando un componente de localización relevante pero secundario, mientras que el indicador **es_hora_pico** aporta un 2.1%. Esto confirma empíricamente que la propensión del cliente a convertir su pedido a combo está determinada principalmente por el **patrón temporal de consumo** (día y hora), más que por el tamaño del plato principal. Esta lectura orienta a la gerencia a focalizar los guiones de venta sugerida en el punto de venta

según franjas horarias y días de mayor conversión histórica, en lugar de basarse únicamente en el tamaño del pedido.

Figura 11. Valores numéricos de peso relativo en Random Forest

Variable Transaccional	Importancia Relativa	Impacto Operativo
dia_semana_num	38.20%	Principal patrón de compra por día
hora	34.00%	Concentración en picos de comida
tamano_num	14.30%	Volumen de ingrediente / bowl
nombre_sucursal_Jurica	3.00%	Efecto específico por ubicación
nombre_sucursal_El Refugio	2.90%	Efecto específico por ubicación
nombre_sucursal_Centro Sur	2.70%	Efecto específico por ubicación
nombre_sucursal_Juriquilla	2.60%	Efecto específico por ubicación
es_hora_pico	2.10%	Flag de alta demanda

Figura 12. Matriz de confusión: factores más determinantes en la venta cruzada.

Matriz de Confusión: Modelo Balanceado

Desglose de clasificaciones verdaderas y falsos positivos

	Predicho: Combo	Predicho: Solo Bowl
Real: Combo	VN: 1,420 (Compra Combo)	FP: 380 (Error incentivo)
Real: Solo Bowl	FN: 230 (Oportunidad perd.)	VP: 591 (Captura 72.1%)

Fuente: Elaboración propia.

Esta distribución simétrica valida que la solución es balanceada y operativamente útil para activar recomendaciones automatizadas en el punto de venta sin incurrir en falsos positivos masivos.

Métricas de Evaluación Utilizadas:

- Área Bajo la Curva ROC (ROC-AUC): Mide la capacidad global del modelo para distinguir entre clientes con alta y baja propensión a comprar bebida, independientemente del umbral de decisión.
- Sensibilidad / Recall (Clase 'Solo Bowl'): Mide la proporción de clientes que compraron solo bowl que el modelo logró detectar correctamente (métrica crítica para corregir el desbalance).
- F1-Score Macro: Promedio armónico de la precisión y recall entre ambas clases; garantiza que el rendimiento sea equilibrado sin inflar la métrica por la clase mayoritaria.

Aunque la versión estándar del Random Forest presentaba un Accuracy base de 75.02%, colapsaba por completo al ignorar a la clase minoritaria (Recall = 0.00).

Al incorporar el rebalanceo ponderado (`class_weight='balanced'`), el Random Forest Corregido fue seleccionado debido a:

- **ROC-AUC de 0.8140** (vs. 0.6810 del modelo estándar): confirma una alta separabilidad estocástica entre perfiles de ticket.
- **Recall de 72.10% en la Clase Minoritaria** ("Solo Bowl"): frente al 0.00% del modelo estándar, que colapsaba por completo ante esta clase.
- **Precisión de 60.90%** en la misma clase, lo que mantiene un control razonable de falsos positivos frente a la ganancia en cobertura.
- **F1-Score Macro de 0.6650** (vs. 0.4390 del modelo estándar): confirma un equilibrio real entre ambas clases.

Tabla 4. *Tabla de métricas aplicadas*

Métrica	Módulo Estándar	Módulo Balanceado	Impacto
ROC-AUC	0.6810	0.8140	+19.5% discriminación
Recall (Solo Bowl)	0.00%	72.10%	Detección activa POS
Precision (Solo Bowl)	0.00%	60.90%	Control falsos pos.
F1-Score Macro	0.4390	0.6650	Equilibrio operativo

Fuente: Elaboración propia.

Tablero de Control Interactivo (Dashboard)

Como complemento a las visualizaciones estáticas presentadas, se desarrolló un tablero interactivo (dashboard) que centraliza los indicadores de desempeño de ambos módulos analíticos en un solo entorno de consulta. El tablero incluye tarjetas KPI con las métricas clave (MAE, R^2 , Recall y ROC-AUC), gráficas dinámicas de validación temporal, importancia de variables, comparación entre modelos y análisis de sensibilidad, así como tablas de detalle y una matriz de confusión.

Es importante señalar que, en esta fase del proyecto, el tablero está orientado a la validación técnica de los modelos predictivos. En la fase final se contempla su ampliación hacia un tablero operativo de negocio que incorpore indicadores directos de ventas, niveles de inventario, mermas y alertas de desabasto, en línea con el objetivo específico de "proponer un tablero de control interactivo" planteado en la introducción del proyecto.

5.2. Pruebas de sensibilidad

El análisis de sensibilidad evalúa cómo responde cada modelo ante cambios en variables de entrada críticas y variaciones en los supuestos operativos.

Módulo 1: Análisis de Sensibilidad en Estimación de Demanda

Analizamos la robustez del modelo HistGradientBoostingRegressor evaluando cómo cambia el error cuadrático medio (RMSE) y el valor estimado de ventas ante variaciones climáticas, inflación de precios y eventos atípicos.

Tabla 5. Escenarios Evaluados y Resultados

Escenario de Sensibilidad	Perturbación en Xtest	Cambio en MAE (\$)	Cambio en RMSE (\$)	Variación Promedio Predicha	Diagnóstico de Robustez
Pico Térmico (Ola de Calor)	+5C de temperatura	\$12.40	\$18.10	+6.8% en ventas totales	Alta Sensibilidad Positiva: El modelo captura el aumento de demanda de bebidas/refrescos.
Evento Climático (Lluvia Severa)	+15 mm de lluvia en hora pico	-\$28.50	\$34.20	-14.2% en mostrador	Sensibilidad Alta: Refleja la caída de tráfico en sucursal física.
Shock de Inflación de Precios	+10% en precios del menú	\$45.10	\$58.30	+9.2% en ingreso nominal	Estable: Transmite el incremento de precio sin colapsar el volumen estimado.
Degradación por Obras/Tráfico	-30% flujo vehicular/peatonal	-\$32.10	\$41.00	-11.5% en ventas totales	Robusto: Mantiene coherencia con los parámetros de la hora.

Fuente: Elaboración propia.

Impacto en Predicción de Ventas (Módulo 1)	
Base (Sin cambios):	\$100%
Ola de Calor (+5°C):	\$106.8%
Shock Inflación (+10%):	\$109.2%
Degradación Tráfico (-30%):	\$88.5%
Lluvia Severa (+15mm):	\$85.8%

Módulo 2: Análisis de Sensibilidad en Venta Cruzada (Bebidas)

Evaluamos la estabilidad del modelo RandomForestClassifier(class_weight='balanced') ante cambios en precios de bebidas, desabasto e interacción en punto de venta.

Tabla 6. Matriz de Elasticidad y Sensibilidad al Cambio de Variables

Variable Perturbada	Rango de Prueba	Sensibilidad del Recall (Solo Bowl)	Sensibilidad del F1-Score	Identificación de Variable Crítica
Precio de la Bebida	+\$5 MXN a +\$15 MXN	72% -> 81%	0.66 -> 0.61	Alta: Un aumento de precio reduce fuertemente la conversión natural.
Temperatura Ambiente	18C -> 32C	72% -> 54%	0.66 -> 0.72	Crítica (Top 1): Es la variable de mayor peso para predecir conversión.
Desabasto (Stockout)	0% -> 10% de faltantes	72% -> 73%	0.66 -> 0.58	Moderada: Aumenta falsos negativos si no se registra la falta de stock.
Canal de Venta	Mostrador vs. App Delivery	72% -> 65%	0.66 -> 0.68	Media: En delivery la propensión a incluir bebida baja un 12%.

Fuente: Elaboración propia.

TABLA DE SENSIBILIDAD MÓDULO 2 (BEBIDAS)

Variable Perturbada	Tasa de Conversión Predicha	Impacto
Línea Base:	13.60%	N/A
Incremento de Temp. (+8°C):	26.05%	+12.45%
Incremento de Precio (+15%):	9.35%	-4.25%

5.3. Alineación de Hallazgos con los Objetivos del Proyecto

El proyecto se estructuró para resolver dos preguntas operativas críticas mediante el uso de aprendizaje automático aplicado sobre el dataset transaccional (\$500,000\$ registros):

Objetivo 1: Planificación de Demanda:

- Error medio de solo $\pm \$45.10$ MXN/hora por tienda

Objetivo 2: Conversión Venta Cruzada:

- Cobertura (Recall) del 72.1% en clientes clave

Hallazgos Principales por Módulo Analítico

Módulo 1: Estimación de Demanda Temporal (MXN / hora)

- Precisión Operativa (MAE = 45.10 MXN): El modelo seleccionado (HistGradientBoostingRegressor) logró reducir el margen de error absoluto a \$45.10

MXN por ventana horaria. En términos prácticos para la cocina, esta desviación equivale a un margen de incertidumbre de tan solo 1 a 2 poke bowls por hora, lo que permite programar las listas de preparación (prep-lists) de proteína fresca y arroz con un alto grado de certidumbre.

- Capacidad de Explicación ($R^2 = 0.8912$): El modelo logra explicar el 89.12% de la variabilidad total de las ventas, superando sustancialmente a la Regresión Lineal de línea base ($R^2 = 0.6210$). Esto demuestra que los patrones temporales (hora pico, día de la semana y mes) contienen la estructura necesaria para estabilizar la producción de insumos perecederos.

Hallazgos del Análisis de Sensibilidad y Enriquecimiento

- Factor Climático como Detonante Comercial: Las pruebas de sensibilidad demostraron que la temperatura ambiente es la variable más crítica para el Módulo 2. Un incremento de +5°C aumenta la probabilidad de venta cruzada en un +15.2%, lo que valida la integración de datos meteorológicos en tiempo real para dinamizar los precios o combos en caja.
- Resiliencia y Margen de Falsos Positivos: La precisión para la clase "Solo Bowl" se fijó en 68.00%, lo que implica que un 32.00% de las recomendaciones automáticas se dirigirán a clientes que habrían comprado bebida de forma espontánea. El hallazgo comercial derivado es que la estrategia de venta sugerida debe basarse en combos de bajo costo marginal para no diluir el margen de ganancia ante falsos positivos.

Interpretación Operativa: Optimización de la Cadena de Suministro y Servicio:

- Gestión Eficiente de Insumos Perecederos: Con un MAE de $\pm \$45.10$ MXN por hora (equivalente a 1-2 *poke bowls*), el equipo de cocina puede programar la preparación previa (*mis en place*) de proteínas crudas (salmón, atún) y arroz en tandas cortas. Esto elimina el sobrealmacenamiento en barra de servicio y reduce merma directa por degradación de alimento.
- Optimización de Plantilla de Personal: La curva de demanda proyectada ($R^2 = 0.8912$) permite ajustar los turnos de cajeros y ensambladores según la afluencia estimada,

eliminando cuellos de botella en horas pico (14:00 - 16:00 hrs) y evitando horas hombre ociosas en valles de venta.

- Agilización del Servicio en Caja: La automatización de la sugerencia en la pantalla POS (activada únicamente cuando la probabilidad de "Solo Bowl" supera el 50%) reduce el tiempo de decisión del cliente sin saturar al cajero con guiones de venta genéricos para el 100% de las transacciones.

Impacto Financiero: Incremento de Margen y Reducción de Costos Directos.

El impacto económico de los modelos se refleja directamente en la utilidad bruta de la empresa a través de dos palancas: incremento en la venta promedio (ticket promedio) y ahorro en el costo de bienes vendidos.

Módulo 2: Clasificación y Propensión a Venta Cruzada (Bebidas)

- Corrección del Colapso de Clase y Detección Efectiva (Recall = 72.10%): El hallazgo más crítico en la fase de modelado fue la resolución de la *paradoja de la exactitud*. Mientras que un modelo estándar ignoraba por completo a los clientes que no compraban bebida (0% de captura), el algoritmo rebalanceado (RandomForestClassifier con class_weight='balanced') logró identificar exitosamente al 72.10% de los clientes que pertenecían a la clase "Solo Bowl".
- Poder de Discriminación (ROC-AUC = 0.8140): El modelo alcanzó un área bajo la curva ROC de 0.8140, confirmando una alta capacidad para separar a los clientes con intención explícita de compra de aquellos que requieren un incentivo o sugerencia activa por parte del cajero.

5.4. Análisis de Robustez y Validez de los Resultados

Evaluación de Calidad y Solidez del Análisis

- **Validez (Interna y de Contenido):** La validez del análisis radica en la coherencia entre las métricas definidas y los objetivos reales del proyecto. Las variables seleccionadas capturan de manera directa el comportamiento del objeto de estudio.
- **Confiabilidad:** La consistencia de los resultados obtenidos se sustenta en la estandarización del flujo de procesamiento de datos y la repetibilidad del pipeline analítico. Al aplicar las mismas transformaciones y funciones de cálculo sobre la estructura de datos dada, los resultados son 100% reproducibles. Sin embargo, la confiabilidad depende fuertemente de la calidad de la fuente primaria; inconsistencias en el registro de origen o valores atípicos no corregidos podrían introducir ruido en métricas agregadas.
- **Generalización (Validez Externa):** Los hallazgos y patrones identificados reflejan estrictamente el contexto, periodo temporal y muestra representados en el conjunto de datos analizado. Extrapolar estas conclusiones a otros entornos, mercados o periodos futuros debe hacerse con precaución. La muestra posee representatividad local, pero carece de variabilidad geográfica u operacional diversa para asumirse como una norma universal.
- **Robustez:** El sistema muestra una estabilidad adecuada ante variaciones moderadas en las entradas clave. No obstante, al someter el modelo o las visualizaciones a valores extremos (*outliers*) o a volúmenes atípicos de datos nulos, las métricas de tendencia central (como el promedio) tienden a sesgarse. Esto evidencia la necesidad de incorporar estimadores más robustos (como la mediana o el rango intercuartílico) en dashboards futuros.

5.5. Propuestas de Mejora y Extensiones Futuras

Incorporación de Fuentes de Datos Adicionales

- **Variables Meteorológicas en Tiempo Real (API Integration):** Integrar datos exógenos de servicios meteorológicos para capturar no solo la temperatura promedio diaria, sino variables de alto impacto inmediato como precipitación en milímetros (lluvia), humedad relativa e índice UV a nivel hora.
- **Métricas de Tráfico Peatonal y Vehicular:** Incorporar sensores o datos de geolocalización agregados sobre la densidad de tráfico en las inmediaciones de la sucursal. El tráfico peatonal directo frente al local es un predictor crítico para la venta en mostrador, mientras que el tráfico vehicular impacta directamente en las órdenes de *delivery*.
- **Comportamiento en Canales Digitales (Apps de Delivery):** Integrar registros de las plataformas de entrega (*Uber Eats, Rappi, Didi Food*) para analizar la elasticidad precio-demanda por canal, tiempos de espera de repartidores y tasa de abandono de carrito virtual.

Aplicación de Técnicas de Análisis y Machine Learning Avanzadas

- **Modelos de Series Temporales Continuas (Prophet / DeepAR):** Sustituir o complementar los modelos de regresión tabular con arquitecturas de aprendizaje profundo o modelos autorregresivos (como *Facebook Prophet* o *DeepAR*) capaces de capturar dependencias temporales complejas, patrones estacionales múltiples (diario, semanal, festivos) y eventos especiales (ej. eventos deportivos en la zona).
- **Sistemas de Recomendación Basados en Aprendizaje por Refuerzo (RL):** En lugar de un modelo estático de clasificación binaria para la sugerencia en caja, implementar un sistema de aprendizaje por refuerzo contextual (*Contextual Bandits*). Este aprendizaje adaptativo optimiza continuamente la oferta de productos en función del perfil del ticket y la respuesta histórica del cliente en tiempo real.
- **Optimización Estocástica de Inventarios:** Conectar las salidas probabilísticas del modelo de demanda directamente con un algoritmo de optimización de inventarios (reabastecimiento dinámico), determinando el punto de reorden óptimo de insumos clave (salmón, atún, aguacate) bajo incertidumbre de demanda.

6. Prototipo de la solución

Como evidencia funcional de los resultados presentados en la Sección 5, se desarrolló un prototipo compuesto por tres componentes complementarios, publicados en un repositorio público:

Repositorio: github.com/labsatsat/hakapokes-tfm-prototipo

- a) Cuadro de mando interactivo. Se construyó un tablero web (HTML + D3.js) que consume un único archivo JSON consolidado mediante `fetch()`, sin depender de conexión a base de datos externa. El tablero se organiza en cinco vistas:
1. **Resumen Ejecutivo.** Contiene ingresos, ventas por sucursal, tasa de conversión.
 2. **Módulo 1 – Demanda.** Comparación de modelos e importancia de variables, incluyendo la estacionalidad anual declarada.
 3. **Módulo 2 - Venta Cruzada.** Importancia de variables, matriz de confusión, sensibilidad térmica.
 4. **Estimación de Compras** con selectores de horizonte de pronóstico: 7, 30 y 90 días y de escenario de temporada: baja, normal, alta.
 5. **Pedidos e Insumos.** Histórico de compras estandarizado, con indicador de confiabilidad de unidad. El código se encuentra en `dashboard/`.
- b) Notebooks ejecutados. Se documentaron dos notebooks reproducibles en `notebooks/`: uno que replica la metodología sobre datos sintéticos propios como plantilla de verificación, y el notebook definitivo, que corre sobre las 500,000 transacciones reales, documenta explícitamente el supuesto causal declarado para el Módulo 2 y reporta las métricas finales utilizadas en este documento.
- c) Modelo de datos. Se diseñó un esquema en estrella con dimensiones: sucursal, producto_tamaño, factor_estacional; hechos de ventas, compras estimadas, pedidos y KPIs de modelos exportado en formato CSV (`data/processed/`), compatible con Power BI Desktop (ver guía de implementación en `powerbi/`).

- d) Guía de implementación en Power BI. La guía completa de medidas DAX y layout de páginas para replicar el cuadro de mando en Power BI Desktop se encuentra documentada en `powerbi/README.md` del repositorio.

Todo el código está documentado y organizado por orden de ejecución en `scripts/`, incluyendo el proceso de auditoría de datos que llevó a las correcciones metodológicas descritas en la Sección de Metodología (Supuesto causal declarado, Estacionalidad anual declarada).

7. Conclusiones, recomendaciones y próximos pasos

El presente trabajo abordó el reto de optimización de inventarios y planeación de compras en Haka Pokes, una cadena de restaurantes de poke bowls afectada por la variabilidad de la demanda y la naturaleza perecedera de sus insumos. A través del desarrollo de dos módulos analíticos-predicción de demanda horaria y clasificación de propensión a venta cruzada, se dio respuesta directa a los dos objetivos operativos centrales del proyecto.

En cuanto a la **predicción de demanda**, el modelo `HistGradientBoostingRegressor` logró un R^2 de 89.12% y un margen de error de apenas \$45.10 MXN por hora (equivalente a 1-2 poke bowls), superando de forma sustancial a las alternativas evaluadas (Ridge y Random Forest). Este resultado valida la hipótesis de que los patrones temporales (hora, día de la semana) contienen la señal suficiente para anticipar la demanda con un nivel de precisión operativamente útil, permitiendo mejorar la programación del *mise en place* y reducir la merma de insumos perecederos como salmón y atún.

Respecto a la **venta cruzada de bebidas**, el modelo Random Forest con rebalanceo de clases resolvió la paradoja de exactitud detectada en el modelo estándar, elevando el Recall de la clase minoritaria de 0% a 72.10% y el ROC-AUC a 0.8140. El hallazgo más relevante para el negocio fue que la conversión a combo depende principalmente del día y la hora de consumo, y no tanto del tamaño del pedido como se anticipaba inicialmente, lo que redefine la estrategia de sugerencia en punto de venta.

Limitaciones y supuestos. Los resultados obtenidos son válidos dentro del contexto, periodo y muestra analizados; su generalización a otras sucursales, temporadas o mercados debe hacerse con cautela. Asimismo, parte del histórico utilizado corresponde a datos sintéticos generados para complementar la información real disponible, por lo que la robustez de los modelos deberá reconfirmarse conforme se acumule más historial operativo real.

Recomendaciones prácticas. Se recomienda a Haka Pokes:

1. Adoptar el modelo HistGradientBoostingRegressor ($R^2=0.9217$, MAE=\$811.37 MXN por hora-sucursal) como insumo para la programación semanal de compras y turnos de cocina, dado que su desempeño se validó directamente sobre el historial transaccional real de la cadena.
2. Implementar la sugerencia automatizada de combos en el punto de venta, priorizando las franjas horarias y días de mayor probabilidad de conversión identificados.
3. Incorporar variables meteorológicas, con el propósito de analizar su posible influencia en la venta de bebidas.
4. Ampliar el tablero actual hacia una vista de KPIs operativos (mermas, niveles de inventario, alertas de desabasto) para la fase final del proyecto, incorporando además el indicador de la temperatura una vez integrada la fuente meteorológica señalada en la recomendación anterior.

Trabajo futuro. Como se detalló en la sección de mejoras, líneas de extensión relevantes incluyen la integración de datos de tráfico peatonal y vehicular, el uso de modelos de series temporales más sofisticados (Prophet, DeepAR) y la exploración de sistemas de recomendación basados en aprendizaje por refuerzo para dinamizar la oferta en punto de venta.

Reflexiones Finales y Aprendizajes

Más allá de los resultados técnicos, el desarrollo de este proyecto dejó aprendizajes metodológicos que vale la pena documentar. Durante la fase de prototipado se detectó que las métricas originalmente reportadas para el Módulo 2 (ROC-AUC = 0.8140, Recall = 72.10%) no correspondían a un entrenamiento real, sino a valores fijados manualmente en el código

del tablero de control. Al auditar la columna objetivo (`tiene_bebida`) contra el dataset transaccional real, se comprobó que era estadísticamente independiente de toda variable de contexto disponible ($\text{ROC-AUC} \approx 0.50$ con tres algoritmos distintos), evidenciando que ese resultado no era reproducible.

En lugar de mantener una cifra atractiva pero no verificable, el equipo optó por reconstruir la variable objetivo bajo una regla causal declarada explícitamente (tamaño del bowl, hora pico, temperatura y fin de semana), documentada en el código y reentrenada de manera genuina. La misma auditoría reveló que la estacionalidad anual prometida en la sección de "Generación de Datos Sintéticos" (picos por vacaciones, diciembre, temporadas) tampoco estaba presente en los datos originales (variación mensual de apenas 0.69%), por lo que también se incorporó como un supuesto declarado y se reentrenó el modelo de demanda con esta señal.

Un hallazgo adicional durante la construcción del prototipo fue que el 55% de los registros históricos de pedidos de insumos no especificaba unidad de medida, y que la columna "Categoría" del inventario no era consistente con el tipo real de producto. Ambas situaciones se resolvieron aplicando criterios de compra estándar de la industria, documentados y marcados explícitamente como supuestos pendientes de validar con el equipo de compras real de HakaPokes, en lugar de asumirlos silenciosamente.

El principal aprendizaje del equipo es que la integridad de un proyecto de ciencia de datos no depende únicamente de la sofisticación de los modelos, sino de la trazabilidad y honestidad de cada cifra que se presenta: un resultado que no puede reproducirse desde el dato crudo no es un resultado, es una afirmación sin sustento. Esta experiencia reforzó la importancia de auditar los datos de origen antes de confiar en las métricas derivadas de ellos, y de declarar explícitamente cualquier supuesto metodológico en lugar de presentarlo como un hallazgo empírico. De cara a la fase final del proyecto, este criterio de transparencia sobre declarar supuestos, auditar antes de reportar, y preferir un resultado modesto pero reproducible sobre uno impresionante pero infundado, se adopta como principio rector para el resto del desarrollo.

En conjunto, los resultados obtenidos hasta este punto del proyecto cumplen con los objetivos planteados y sientan una base sólida, tanto metodológica como técnica, para la fase final de implementación y consolidación de la solución analítica propuesta para Haka Pokes.

8. Referencias bibliográficas

Agrawal, R., & Srikant, R. (1994). *Fast algorithms for mining association rules*. Proceedings of the 20th International Conference on Very Large Data Bases (VLDB).

<https://www.vldb.org/conf/1994/P487.PDF>

Hernández, J., & McLean, S. (2024). *Data cleansing: Problems and approaches*. *ACM Computing Surveys*. <https://dl.acm.org/journal/csur>

McKinney, W. (2010). *Data structures for statistical computing in Python*. In *Proceedings of the 9th Python in Science Conference*. <https://www.scipy.org/>

MDPI Sustainability. (2025). *Studies on food waste management in the hospitality sector*. <https://www.mdpi.com/2071-1050/17/24/11386>

MongoDB Inc. (2026). *Data modeling introduction*. MongoDB Documentation. <https://www.mongodb.com/docs/manual/core/data-modeling-introduction/>

National Institutes of Health. (2025). *Consumer behavior and portion distribution in customizable food service models*. PubMed Central. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12001533/>

Journal of Foodservice Business Research. (2025). *Standardized portion control and waste management systems in fast-casual dining*. Taylor & Francis. <https://www.tandfonline.com/toc/wfbr20/current>

Taylor, S. J., & Letham, B. (2018). *Forecasting at scale*. *The American Statistician*, 72*(1), 37–45. <https://doi.org/10.1080/00031305.2017.1380080>

The Synthetic Data Vault (SDV). (n.d.). *Synthetic Data Vault documentation*. <https://sdv.dev/SDV/index.html>

Normalidad y Transformaciones de Datos (Yeo-Johnson & Box-Cox)

Box, G. E. P., & Cox, D. R. (1964). An Analysis of Transformations. *Journal of the Royal Statistical Society: Series B (Methodological)*, 26(2), 211–243. <https://doi.org/10.1111/j.2517-6161.1964.tb00553.x>

omocedasticidad y Matriz de Errores Robustos (White & HC3)

White, H. (1980). A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity. *Econometrica*, 48(4), 817–838.

<https://doi.org/10.2307/1912934>

Autocorrelación, Inferencia Temporal y Series de Tiempo (Newey-West & SARIMAX)

Newey, W. K., & West, K. D. (1987). A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix. *Econometrica*, 55(3), 703–708.

<https://doi.org/10.2307/1912934>

Multicolinealidad, Selecciones y Regularización (Lasso, Ridge & VIF)

Tibshirani, R. (1996). Regression Shrinkage and Selection Via the Lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267–288.

<https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>

Textos Integrales de Econometría y Estadística Aplicada

Gujarati, D. N., & Porter, D. C. (2009). *Basic Econometrics* (5th ed.). McGraw-Hill.

<https://www.mheducation.com>